



UNIVERSIDAD
SAN SEBASTIAN
VOCACIÓN POR LA EXCELENCIA

ADVANCE|USS

Evaluación: Solemne 2

Asignatura: Introducción a la Ciencia de Datos



Evaluación: Solemne 2

Contenido(s):

Construcción de un Modelo de clasificación y de asociación a partir de datos reales.

Actividades:

Los y las estudiantes deberán aplicar los conocimientos adquiridos para desarrollar un programa en Python que construya un clasificador y un modelo de asociación.

Descripción del trabajo

Este trabajo tiene como objetivo verificar las habilidades adquiridas en cuanto a la manipulación y carga de datos con Pandas, el preprocesamiento de Datos para Machine Learning y clasificación con Machine Learning, la evaluación del Rendimiento del Modelo, aplicación de modelo de Asociación y la extracción de información útil para negocios.

Resultados de Aprendizaje

Utiliza Python para construir los modelos de ciencia de datos, a través de un análisis racional y reflexivo de diversos casos de estudio.

Carácter

Individual

Metodología

ABP

Recursos complementarios:

<https://archive.ics.uci.edu/datasets>

<https://colab.google/>

Duración

1 hora directa y 1,5 horas indirectas distribuidas en 1 sesión.

Evaluación

Rúbrica.

Requisitos técnicos (en caso de ser necesario)

- **Computadoras con Python instalado (Anaconda/Jupyter Notebook/Google Colab recomendado).**
- **Librerías Python: pandas, numpy, matplotlib, seaborn, scikit-learn, Streamlit, Dash, Plotly.**
- **Conexión a internet.**
- **Jupyter notebook de Anaconda o bien Python.**
- **Los scripts del ejemplo proporcionados previamente (como base).**



Este trabajo presenta características como:

Talleres Prácticos:

Realizar tareas prácticas relacionadas con el tema del taller, como la programación, la construcción, la escritura, etc.

Ejercicios de Reflexión individual:

Dar tiempo para que los participantes reflexionen sobre lo aprendido y cómo aplicarlo en su contexto personal o profesional.

Proyectos de Aplicación:

Encargar proyectos que los participantes deben completar utilizando las habilidades y conocimientos adquiridos durante el taller.



Instrucciones de la actividad:

Para la realización de esta evaluación deberás desarrollar un modelo predictivo de clasificación que permita determinar si un solicitante de crédito es de "buen crédito" o "mal crédito" y descubrir patrones de asociación entre las características de los solicitantes, utilizando el dataset German Credit Data de <https://archive.ics.uci.edu> y las Fases de la Metodología CRISP_DM.

Con mayor precisión un "buen crédito" (Good) significa que el solicitante es considerado de bajo riesgo de incumplimiento (default). En términos de negocio, esto implica que se espera que esta persona pague su préstamo en su totalidad y a tiempo, lo que generará ingresos por intereses para la entidad financiera. Son clientes deseables a los que el banco quiere prestar dinero.

Contexto del Problema

Una institución financiera en Alemania busca optimizar la aprobación de créditos, minimizando el riesgo de impagos y maximizando los créditos otorgados a clientes confiables.

Objetivos de Ciencia de Datos

- Clasificación: Construir un árbol de decisión para clasificar solicitantes como "Good" (buen crédito) o "Bad" (mal crédito) y comprender los atributos más relevantes para el problema.
- Asociación: Identificar patrones y reglas de asociación que describan combinaciones de características asociadas a un buen o mal crédito.

Preguntas a responder

1. ¿Cuáles son las variables más influyentes según el árbol de decisión en la predicción del riesgo crediticio? Indique 3.
2. ¿Qué describen las 3 principales reglas con mayor soporte y confianza?
3. ¿Qué estrategia comercial se podría derivar del árbol decisión? Describa 2.
4. ¿Qué estrategia comercial se podría derivar desde las reglas de asociación? Describa 2.

Atributos Utilizados del Dataset

El dataset original contiene 1000 registros y 21 atributos (20 predictores + 1 objetivo). Sin embargo, deberá trabajar con un archivo que solo contiene 11 atributos (10 predictores + 1 objetivo) y que estará disponible para la prueba que seleccione, de todas maneras, puede obtener más información de los atributos desde la URL indicada anteriormente.

El archivo de datos a utilizar es "german.data.C.csv"



Los atributos para la versión C, son:

- **CreditStatus:** Variable objetivo (1 = Good, 2 = Bad).
- **DurationMonth:** Este atributo numérico representa la duración del préstamo en meses. Valores comunes incluyen picos en 12 y 24 meses, lo que indica que muchos préstamos son de corto a mediano plazo.
- **CreditHistory:** Este atributo cualitativo describe el historial crediticio del solicitante. Los códigos son: A30 (sin créditos/todos pagados), A31 (créditos pagados), A32 (buen historial), A33 (retrasos ocasionales), y A34 (cuenta crítica/otros créditos en otros bancos).
- **Purpose:** Este es un atributo cualitativo que especifica el propósito del crédito. Los códigos incluyen: A40 (automóvil nuevo), A41 (automóvil usado), A42 (muebles/equipo), A43 (radio/televisión), A44 (electrodomésticos), A45 (reparaciones), A46 (educación), A47 (vacaciones), A48 (formación profesional), y A49 (otros).
- **CreditAmount:** Este atributo numérico representa el monto total del crédito solicitado. La descripción del problema indica que está sesgado hacia valores bajos, lo que significa que la mayoría de los préstamos son por cantidades pequeñas.
- **InstallmentRate:** Este atributo numérico indica la tasa de cuota del crédito como un porcentaje del ingreso disponible. Sus valores se clasifican de 1 a 4, donde 1 representa una tasa de cuota muy alta ($>35\%$ del ingreso) y 4 una tasa de cuota baja ($\leq 2\%$ del ingreso).
- **Age:** Un atributo numérico que representa la edad del solicitante en años, un factor demográfico clave en la evaluación del riesgo crediticio.
- **OtherInstallmentPlans:** Atributo cualitativo que se refiere a otros planes de pago a plazos que el solicitante pueda tener. Los códigos son: A141 si los tiene en un banco, A142 si los tiene en una tienda, y A143 si no tiene otros planes de pago.
- **Housing:** Un atributo cualitativo que describe la situación de vivienda del solicitante. Los códigos son: A151 (vivienda de alquiler), A152 (vivienda propia), y A153 (vivienda gratuita).
- **NumExistingCredits:** Este atributo numérico indica el número de créditos existentes que el solicitante tiene con este banco.
- **Job:** Un atributo cualitativo que describe el tipo de trabajo del solicitante. Los códigos son: A171 (desempleado/no cualificado), A172 (no cualificado/residente), A173 (empleado cualificado/funcionario), y A174 (directivo/autónomo).

Estructura del Taller, según las fases CRISP_DM

- Comprensión del Negocio: Definir objetivos y preguntas clave.
- Comprensión de los Datos: Cargar y explorar el dataset, analizando distribuciones, correlaciones, datos nulos, outliers y desbalance de clases
- Preparación de los Datos:
 - Codificación one-hot de variables categóricas.
 - Balanceo de clases con SMOTE.
 - Discretización de variables numéricas para reglas de asociación.
- Modelado:
 - Clasificación: Implementar un árbol de decisión para predecir CreditStatus.



- Asociación: Aplicar el algoritmo Apriori para identificar los patrones “más” frecuentes.
- Evaluación: Analizar la precisión del modelo de clasificación, las reglas del árbol y los atributos más importantes. Analizar las reglas de asociación.
- Despliegue: Utilizar el conocimiento adquirido para proponer estrategias de negocio o recomendaciones.

Entregables

Entregue su trabajo en un archivo jupyter “.ipynb” (donde incluya el código, las salidas parciales, comentarios y respuestas solicitadas en la rúbrica). Se permite el uso de IA.