



UNIVERSIDAD
SAN SEBASTIAN
VOCACIÓN POR LA EXCELENCIA

ADVANCE|USS

Apunte: Conociendo casos de estudio para las reglas de asociación

Unidad 3: Publicación de Modelos de Ciencia de Datos y Casos de Estudio

Asignatura: Introducción a la Ciencia de Datos



Tabla de contenido

Contenido

Introducción	2
1. Casos de estudio usando reglas de asociación	3
1.1. Análisis de canasta de compra (Market basket analysis)	3
1.2. Sistemas de recomendación en comercio electrónico	3
1.3. Detección de fraudes en transacciones financieras	4
1.4. Análisis de secuencias genómicas en bioinformática	4
1.5. Optimización de inventarios en cadenas de suministro	4
1.6. Análisis de comportamiento del cliente en marketing digital	5
1.7. Detección de efectos secundarios en farmacovigilancia	5
1.8. Análisis de fallos en sistemas de manufactura	5
1.9. Análisis de patrones de tráfico en redes de telecomunicaciones	6
1.10. Análisis de comportamiento en redes sociales.....	6
2. Estudio de casos reales de asociaciones en ciencia de datos.....	7
2.1. Artículo “Product Sales Promotion Recommendation Strategy with Purchase Pattern Analysis FP-Growth Algorithm”	7
1.2. Artículo “Developing an Efficient FP-Growth Algorithm using Ordered Frequent Itemsets Matrix for Big Data”	10
Conclusión	14
Referencias bibliográficas	15



Introducción

El presente apunte tiene como propósito ofrecer un análisis detallado de los conceptos, metodologías y aplicaciones vinculadas al uso de herramientas avanzadas para la gestión y el análisis de datos. Se abordan enfoques prácticos que permiten transformar información compleja en insumos claros y organizados, facilitando así la toma de decisiones fundamentadas en diversos contextos profesionales.

A lo largo del contenido, se presentan técnicas y procedimientos que integran herramientas tecnológicas especializadas, con el objetivo de optimizar la recopilación, organización y representación visual de la información. Se enfatiza la importancia de seleccionar y aplicar métodos apropiados para cada necesidad, así como de interpretar los resultados de manera crítica y coherente con los objetivos definidos.

Asimismo, el apunte plantea ejemplos y casos que permiten comprender el valor estratégico de una gestión eficiente de datos, destacando cómo su correcta aplicación puede mejorar procesos, identificar patrones relevantes y generar ventajas competitivas. Todo ello se enmarca en un enfoque práctico que conecta el aprendizaje técnico con escenarios reales de desempeño profesional.



1. Casos de estudio usando reglas de asociación

A continuación, se presentan 10 casos distintos de estudio, éxito o aplicación de las reglas de asociación. Las reglas de asociación son técnicas de minería de datos que identifican relaciones frecuentes entre elementos en grandes conjuntos de datos, comúnmente representadas como "si-entonces" (e.g., {A} → {B}). Estas reglas son ampliamente utilizadas en análisis de mercado, recomendación de productos, detección de fraudes, bioinformática, entre otros. Cada caso incluye una descripción, un ejemplo de uso, las técnicas o algoritmos más usados y una referencia relevante.

1.1. Análisis de canasta de compra (*Market basket analysis*)¹

El análisis de canasta de compra utiliza reglas de asociación para identificar patrones de compra en transacciones minoristas, ayudando a las empresas a optimizar la disposición de productos, promociones y estrategias de *marketing*. Es una aplicación masiva en supermercados, tiendas en línea y comercio electrónico.

Un ejemplo de uso es en un supermercado, el análisis de transacciones revela que los clientes que compran pan y mantequilla también tienden a comprar jamón. La regla de asociación {pan, mantequilla} → {jamón} permite al supermercado colocar estos productos cerca o crear promociones combinadas para aumentar las ventas.

Dentro de las técnicas o modelos más usados tendremos los algoritmos Apriori y FP-Growth son los más comunes para generar reglas de asociación debido a su eficiencia en encontrar *itemsets* frecuentes. También se usan métricas como soporte, confianza y *lift* para evaluar la calidad de las reglas.

1.2. Sistemas de recomendación en comercio electrónico²

Los sistemas de recomendación utilizan reglas de asociación para sugerir productos a los usuarios basándose en sus compras o interacciones previas, siendo una aplicación clave en plataformas como Amazon o Netflix. Mejoran la experiencia del usuario y aumentan las ventas.

Un ejemplo de uso es en Amazon, donde un cliente que compra una cámara y un trípode recibe la recomendación de una bolsa para cámara. La regla {cámara, trípode} → {bolsa para cámara} se deriva de patrones de compra frecuentes en la base de datos de transacciones.

En cuanto a las técnicas o modelos más usados, tendremos algoritmos como Apriori y FP-Growth identifican *itemsets* frecuentes, mientras que técnicas colaborativas basadas en reglas de asociación complementan sistemas de filtrado colaborativo. Métricas como confianza y *lift* evalúan la relevancia de las recomendaciones.

¹ Agrawal, R., Imieliński, T. & Swami, A. (1993). *Mining association rules between sets of items in large databases*. Proceedings of the 1993 ACM SIGMOD International Conference on Management of Data, pp. 207-216. doi: 10.1145/170035.170072.

² Schafer, J., Konstan, J. & Riedl, J. (2001). *E-commerce recommendation applications*. Data Mining and Knowledge Discovery, vol. 5, no. 1-2, pp. 115-153. doi: 10.1023/A:1009804230409.



1.3. Detección de fraudes en transacciones financieras³

Las reglas de asociación identifican patrones inusuales en transacciones financieras para detectar actividades fraudulentas, siendo esenciales en bancos y *fintechs* para proteger a los clientes y reducir pérdidas.

Un ejemplo de uso es un banco, donde se analizan transacciones y descubre que {transacciones internacionales, monto elevado, hora inusual} → {fraude potencial}. Esta regla alerta al sistema para bloquear o investigar transacciones sospechosas en tiempo real.

Dentro de las técnicas o modelos más usados están los algoritmos como Apriori y ECLAT se utilizan para encontrar patrones frecuentes en grandes volúmenes de transacciones. También se aplican técnicas de preprocesamiento para discretizar montos y tiempos, y métricas como soporte y confianza para filtrar reglas relevantes.

1.4. Análisis de secuencias genómicas en bioinformática⁴

Las reglas de asociación se utilizan en bioinformática para descubrir relaciones entre genes, proteínas o mutaciones en secuencias genómicas, ayudando a identificar patrones relacionados con enfermedades o funciones biológicas.

Un ejemplo de uso es En un estudio genómico, se encuentra que {mutación en gen A, mutación en gen B} → {predisposición al cáncer}. Esta regla ayuda a los investigadores a priorizar estudios sobre combinaciones de mutaciones específicas.

Algunas técnicas o modelos más usados son algoritmos como Apriori y FP-Growth adaptados a datos biológicos, junto con técnicas de preprocesamiento como alineación de secuencias y discretización de datos genómicos. Métricas como soporte y lift evalúan la significancia biológica de las reglas.

1.5. Optimización de inventarios en cadenas de suministro⁵

Las reglas de asociación identifican patrones en la demanda de productos para optimizar la gestión de inventarios en cadenas de suministro, reduciendo costos y mejorando la eficiencia en sectores como manufactura y logística.

Un ejemplo de uso se da en una fábrica, se descubre que {aumento en la demanda de producto A, temporada de verano} → {demanda de producto B}. Esta regla permite ajustar el inventario de producto B antes del verano para evitar desabastecimiento.

Como técnicas o modelos más usados se pueden mencionar los algoritmos como Apriori y FP-Growth procesan datos históricos de ventas. Se emplean técnicas de discretización para variables temporales y métricas como confianza y *lift* para priorizar reglas útiles.

³ Bhattacharyya, S. et al. (2011). *Data mining for credit card fraud: A comparative study*. Decision Support Systems, vol. 50, no. 3, pp. 602-613. doi: 10.1016/j.dss.2010.08.008.

⁴ Becquet, C. et al. (2002). *Strong-association-rule mining for large-scale gene-expression data analysis: A case study on human SAGE data*. Genome Biology, vol. 3, no. 12, pp. research0067.1–0067.16, 2002. doi: 10.1186/gb-2002-3-12-research0067.

⁵ Han, H., Pei, J. & Yin, Y. (2000). *Mining frequent patterns without candidate generation*. Proceedings of the 2000 ACM SIGMOD International Conference on Management of Data, pp. 1-12. doi: 10.1145/342009.335372.



1.6. Análisis de comportamiento del cliente en *marketing* digital⁶

Las reglas de asociación analizan el comportamiento en línea de los usuarios (clics, visitas, compras) para personalizar campañas de *marketing* digital, mejorando la conversión en sitios *web* y redes sociales.

Un ejemplo de uso se da en una empresa de streaming como Netflix analiza el historial de visualización y la actividad de un usuario. Si el clasificador detecta una disminución en el uso, clasifica al usuario como "en riesgo de abandono", lo que desencadena una oferta de descuento para retenerlo.

En cuanto a las técnicas o modelos más usados, encontraremos: Algoritmos como Apriori y ECLAT procesan datos de navegación. Técnicas de preprocesamiento como segmentación de sesiones y métricas como soporte y confianza identifican patrones relevantes.

1.7. Detección de efectos secundarios en farmacovigilancia⁷

Las reglas de asociación identifican relaciones entre medicamentos y efectos secundarios en bases de datos de farmacovigilancia, ayudando a detectar combinaciones peligrosas y mejorar la seguridad del paciente.

Un ejemplo de uso es en una base de datos de reacciones adversas, se descubre que {medicamento A, medicamento B} → {efecto secundario náuseas}. Esta regla alerta a los médicos sobre posibles riesgos de combinar estos medicamentos.

Dentro de las técnicas o modelos más usados tendremos los algoritmos como Apriori y FP-Growth analizan grandes bases de datos de eventos adversos. Métricas como *lift* y confianza evalúan la fuerza de las asociaciones, con preprocesamiento para estandarizar nombres de medicamentos.

1.8. Análisis de fallos en sistemas de manufactura⁸

Las reglas de asociación identifican patrones de fallos en sistemas de manufactura, ayudando a predecir y prevenir defectos en líneas de producción, mejorando la calidad y reduciendo costos.

Un ejemplo de uso se da en una fábrica de automóviles, se encuentra que {máquina X en alta velocidad, material Y} → {defecto en pintura}. Esta regla permite ajustar la velocidad de la máquina cuando se usa material Y para evitar defectos.

Algunas técnicas o modelos más usados son: Algoritmos como Apriori y ECLAT procesan registros de producción. Se utilizan técnicas de discretización para variables continuas (e.g., velocidad) y métricas como soporte y *lift* para evaluar reglas.

⁶ Zhang, S., Yang, J. & Cheedella, V. (2008). *Mining user behavior for effective online advertising*. Proceedings of the 14th ACM SIGKDD International Conference on Knowledge Discovery and Data Mining, pp. 1038-1046. doi: 10.1145/1401890.1402017.

⁷ Hauben, M & Bate, A. (2009). *Decision support methods for the detection of adverse events in post-marketing data*. Drug Discovery Today, vol. 14, no. 7-8, pp. 343-357. doi: 10.1016/j.drudis.2008.12.012.

⁸ Li, J., Han, J. & Pei, J. (2001). *CMAR: Accurate and efficient classification based on multiple class-association rules*. Proceedings of the 2001 IEEE International Conference on Data Mining, pp. 369-376, 2001. doi: 10.1109/ICDM.2001.989541.



1.9. Análisis de patrones de tráfico en redes de telecomunicaciones⁹

Las reglas de asociación identifican patrones en el tráfico de redes para optimizar el rendimiento, detectar cuellos de botella o prevenir fallos en telecomunicaciones.

Un ejemplo de uso se da en una red 5G, se descubre que {alta carga en hora pico, región urbana} → {caída de conexión}. Esta regla ayuda a los operadores a redistribuir recursos durante horas pico en áreas urbanas.

En cuanto a las técnicas o modelos más usados, encontraremos los algoritmos como FP-Growth y ECLAT procesan datos de tráfico. Técnicas de preprocesamiento incluyen discretización de tiempos y volúmenes de datos, con métricas como confianza y *lift* para priorizar reglas.

1.10. Análisis de comportamiento en redes sociales¹⁰

Las reglas de asociación identifican patrones en las interacciones de usuarios en redes sociales (e.g., *likes*, comentarios, *shares*) para optimizar contenido, detectar tendencias o identificar comunidades.

Un ejemplo de uso se da en Twitter, se encuentra que {usuario comparte publicaciones sobre tecnología, sigue cuentas de startups} → {comenta en posts de IA}. Esta regla ayuda a recomendar contenido de inteligencia artificial a usuarios con este comportamiento.

En cuanto a las técnicas o modelos más usados, encontraremos los algoritmos como Apriori y FP-Growth analizan interacciones sociales. Técnicas de preprocesamiento como tokenización de *hashtags* y métricas como soporte y confianza identifican patrones relevantes.

Notas generales

- **Algoritmos comunes:** los algoritmos Apriori y FP-Growth son los más utilizados debido a su eficiencia en encontrar *itemsets* frecuentes. ECLAT es otra alternativa para *datasets* grandes.
- **Métricas clave:** soporte (frecuencia de un *itemset*), confianza (probabilidad condicional de una regla) y *lift* (fuerza de la relación frente a la aleatoriedad) son esenciales para evaluar reglas de asociación.
- **Preprocesamiento:** la discretización de variables continuas, estandarización de datos y filtrado de *itemsets* poco frecuentes son pasos comunes para mejorar la calidad de las reglas.
- **Aplicaciones amplias:** las reglas de asociación son versátiles y se aplican en dominios tan diversos como comercio, salud, manufactura y telecomunicaciones, como se refleja en los casos presentados.

Estos casos de estudio destacan la relevancia de las reglas de asociación en la resolución de problemas prácticos, con referencias que respaldan su aplicación en contextos reales.

⁹ Zhang, Y., Wang, S. & Phillips, P. (2014). *Mining network traffic data for anomaly detection using association rules*. Computer Networks, vol. 72, pp. 112-123. doi: 10.1016/j.comnet.2014.07.006.

¹⁰ Xu, G., Zhang, Y. & Li, L. (2013). *Mining social media data using association rules for community detection*. Social Network Analysis and Mining, vol. 3, no. 4, pp. 1213-1227. doi: 10.1007/s13278-013-0135-8.



2. Estudio de casos reales de asociaciones en ciencia de datos

A continuación, se profundizará en dos publicaciones donde los datos son accesibles y corresponden a casos reales.

2.1. Artículo “Product Sales Promotion Recommendation Strategy with Purchase Pattern Analysis FP-Growth Algorithm”¹¹

Autores: Ismarmiaty, Ismarmiaty & Rismayati, Ria.

Año: 2023

Problema

El desarrollo de tecnologías en el sector minorista requiere que las empresas utilicen datos de transacciones de ventas para satisfacer las demandas de los clientes y tomar decisiones estratégicas efectivas. En este caso, CV. Busaeri Rattan enfrenta el desafío de identificar patrones de compra para optimizar estrategias de promoción y gestión de inventario, ya que no se analizaban previamente los datos de transacciones para descubrir productos frecuentemente comprados juntos.

Los datos utilizados en el estudio provienen de transacciones de ventas de una farmacia en Indonesia. Los autores describen el *dataset* como transacciones de ventas de medicamentos recolectadas en 2010 y 2011.

El archivo Online Retail¹² es un conjunto de datos transaccional que incluye todas las transacciones realizadas entre el 1 de diciembre de 2010 y el 9 de diciembre de 2011. Proviene de una empresa minorista en línea con sede en el Reino Unido que se dedica principalmente a la venta de regalos para todas las ocasiones, y muchos de sus clientes son mayoristas.

El conjunto de datos contiene 541,909 registros y 8 características:

- **InvoiceNo** (Número de factura): un número integral de 6 dígitos para cada transacción. La letra 'c' indica una cancelación.
- **StockCode** (Código de stock): un número integral de 5 dígitos para cada producto distinto.
- **Description** (Descripción): el nombre del producto.
- **Quantity** (Cantidad): las cantidades de cada producto por transacción.
- **InvoiceDate** (Fecha de factura): el día y la hora de cada transacción.
- **UnitPrice** (Precio unitario): el precio del producto por unidad en libras esterlinas.
- **CustomerID** (ID de cliente): un número integral de 5 dígitos asignado de forma única a cada cliente.

¹¹

https://www.researchgate.net/publication/365042061_Product_Sales_Promotion_Recommendation_Strategy_with_Purchase_Pattern_Analysis_FP-Growth_Algorithm

¹² <https://archive.ics.uci.edu/dataset/352/online+retail>



- **Country** (País): el país de residencia de cada cliente.

Este conjunto de datos es multivariado, secuencial y de series de tiempo, y es relevante para áreas de negocio, pudiendo ser utilizado para tareas de clasificación y agrupación.

Solución

El estudio propone el uso del algoritmo FP-Growth, una técnica de minería de datos, para realizar un análisis de patrones de compra (*market basket analysis*) y generar reglas de asociación que identifiquen combinaciones de productos frecuentemente comprados juntos. Estas reglas se utilizan para recomendar estrategias de promoción, como paquetes de productos o descuentos, y optimizar la gestión de inventario.

Herramientas o softwares utilizados

- **RapidMiner 9.10**: utilizado para implementar el modelo de análisis de asociación con el algoritmo FP-Growth.
- **Microsoft Excel**: empleado para la preparación inicial de los datos de transacciones.

Preparación de los datos

- **Recopilación de datos**: se utilizaron datos de transacciones de ventas de CV. Busaeri Rattan durante tres meses, con un total de 7,772 transacciones y 137,334 productos comprados, abarcando 1,211 tipos de productos.
- **Preparación de datos**: los datos de transacciones y productos se inicializaron en un formato binomial (0 o 1) para cumplir con los requisitos del algoritmo FP-Growth. Esto incluyó la transformación de datos en tablas que representaban las compras de productos por transacción.
- **Filtrado**: se aplicaron umbrales de soporte mínimo (0.01%) y confianza mínima (50%) para generar reglas de asociación relevantes.

Resultados

- El análisis con el algoritmo FP-Growth generó 819 reglas de asociación, de las cuales se filtraron 85 reglas fuertes basadas en los umbrales establecidos.
- Ejemplo de hallazgo: Los productos “Mandola 3/4” y “Jawit 8/11” se compran juntos con un 100% de confianza, lo que indica una fuerte relación de co-compra.
- Estas reglas permiten identificar combinaciones de productos que pueden ser utilizadas para promociones de paquetes, descuentos o estrategias de colocación en tiendas.

Conclusiones

- El algoritmo FP-Growth demostró ser eficiente y escalable para analizar grandes volúmenes de datos de transacciones, superando al algoritmo Apriori en velocidad y uso de recursos.
- Los patrones de compra identificados proporcionan información valiosa para CV. Busaeri Rattan, permitiendo optimizar la gestión de inventario, minimizar el riesgo de desabastecimiento y diseñar estrategias de promoción basadas en datos, como descuentos o paquetes de productos.



- Se recomienda realizar investigaciones futuras para explorar la aplicación del algoritmo FP-Growth en otros tipos de productos o compararlo con otros algoritmos de minería de datos para mejorar las estrategias de ventas.



1.2. Artículo “Developing an Efficient FP-Growth Algorithm using Ordered Frequent Itemsets Matrix for Big Data”¹³

Autores: Mohammed Abdulla Al-Badani, Abdullah Ghaleb Al-Khulaidi

Publicación: International Journal of Intelligent Systems and Applications in Engineering, Vol. 12, No. 3, pp. 508–516, 2024.

El conjunto de datos de hongos contiene descripciones de muestras hipotéticas correspondientes a 23 especies de hongos con branquias de las familias Agaricus y Lepiota. Los datos fueron extraídos de: The Audubon Society Field Guide to North American Mushrooms¹⁴ (1981).

Aquí tienes un resumen de los datos:

- **Clasificación:** cada especie se identifica como definitivamente comestible o definitivamente venenosa. Las especies de comestibilidad desconocida o no recomendada se combinaron con la clase venenosa.
- **Número de instancias:** contiene 8124 observaciones (muestras de hongos).
- **Número de atributos:** tiene 22 atributos (variables) predictivos, todos con valores nominales, además de la clase (comestible/venenoso).
- **Características:** los atributos describen diversas características físicas, visuales y olfativas de los hongos, así como información sobre su hábitat y patrón de crecimiento.

Algunos de los atributos clave y sus posibles valores incluyen:

- **forma-del-sombrero (cap-shape):** campana (b), cónico (c), convexo (x), plano (f), nudoso (k), hundido (s).
- **superficie-del-sombrero (cap-surface):** fibroso (f), ranuras (g), escamoso (y), liso (s).
- **color-del-sombrero (cap-color):** marrón (n), beige (b), canela (c), gris (g), verde (r), rosa (p), púrpura (u), rojo (e), blanco (w), amarillo (y).
- **hematomas (bruises):** tiene hematomas (t), no tiene (f).
- **olor (odor):** almendras (a), anís (l), creosota (c), a pescado (y), fétido (f), a humedad (m), ninguno (n), picante (p), especiado (s).
- **unión-de-lamina (gill-attachment):** adherida (a), descendente (d), libre (f), con muescas (n).
- **espaciado-de-lamina (gill-spacing):** cerca (c), apiñado (w), distante (d).
- **tamaño-de-lamina (gill-size):** ancho (b), estrecho (n).
- **color-de-lamina (gill-color):** negro (k), marrón (n), beige (b), chocolate (h), gris (g), verde (r), naranja (o), rosa (p), púrpura (u), rojo (e), blanco (w), amarillo (y).
- **forma-del-tallo (stalk-shape):** ensanchando (e), ahusado (t).

¹³ <https://ijisae.org/index.php/IJISAE/article/view/5281>

¹⁴ <https://archive.ics.uci.edu/dataset/73/mushroom>



- **raíz-del-tallo (stalk-root)**: bulboso (b), en forma de garrote (c), en forma de copa (u), igual (e), rizomorfos (z), enraizado (r), faltante (?).
- **superficie-del-tallo-arriba-del-anillo (stalk-surface-above-ring)**: fibroso (f), escamoso (y), sedoso (k), liso (s).
- **superficie-del-tallo-abajo-del-anillo (stalk-surface-below-ring)**: fibroso (f), escamoso (y), sedoso (k), liso (s).
- **color-del-tallo-arriba-del-anillo (stalk-color-above-ring)**: marrón (n), beige (b), canela (c), gris (g), naranja (o), rosa (p), rojo (e), blanco (w), amarillo (y).
- **color-del-tallo-abajo-del-anillo (stalk-color-below-ring)**: marrón (n), beige (b), canela (c), gris (g), naranja (o), rosa (p), rojo (e), blanco (w), amarillo (y).
- **tipo-de-velo (veil-type)**: parcial (p), universal (u).
- **color-del-velo (veil-color)**: marrón (n), naranja (o), blanco (w), amarillo (y).
- **número-de-anillos (ring-number)**: ninguno (n), uno (o), dos (t).
- **tipo-de-anillo (ring-type)**: telaraña (c), evanescente (e), abocinado (f), grande (l), ninguno (n), colgante (p), envainado (s), zona (z).
- **color-de-esporas (spore-print-color)**: negro (k), marrón (n), beige (b), chocolate (h), verde (r), naranja (o), púrpura (u), blanco (w), amarillo (y).
- **población (population)**: abundante (a), agrupado (c), numeroso (n), disperso (s), varios (v), solitario (y).
- **hábitat (habitat)**: pastos (g), hojas (l), prados (m), caminos (p), urbano (u), desechos (w), bosques (d).

Este conjunto de datos es comúnmente utilizado en el aprendizaje automático para tareas de clasificación binaria, donde el objetivo es predecir si un hongo es comestible o venenoso basándose en sus características.

Descripción del caso de estudio

Este artículo propone una versión mejorada del algoritmo FP-Growth, denominado *Ordered Frequent Itemsets Matrix* FP-Growth (OFIM-FP-Growth), para la minería de patrones frecuentes en grandes conjuntos de datos. El enfoque se centra en optimizar la eficiencia computacional al reducir el número de escaneos de la base de datos y mejorar la representación de los datos mediante una matriz ordenada de ítems frecuentes. La aplicación se evalúa en el contexto de análisis de datos transaccionales, como los de supermercados y clasificación de hongos, para descubrir patrones frecuentes que puedan usarse en *market basket analysis* o clasificación biológica. Este método es particularmente útil en escenarios de *big data*, donde los volúmenes de datos son masivos y la eficiencia es crítica.

En el conjunto de datos Supermarket del UCI Repository, el algoritmo identifica patrones frecuentes en transacciones de compra, como {leche, pan} → {queso}, indicando que los clientes que compran leche y pan frecuentemente también compran queso. Esto permite a los minoristas optimizar la disposición de productos o crear promociones dirigidas. En el conjunto de datos Mushroom, el algoritmo descubre patrones de características de hongos (e.g., {sombrero convexo, olor fétido} → {venenoso}), útiles para clasificar hongos como comestibles o venenosos.

El artículo utiliza una versión mejorada del algoritmo FP-Growth, que construye un árbol de patrones frecuentes (FP-Tree) y una matriz ordenada de ítems frecuentes para reducir el tiempo de cómputo. Compara su rendimiento con el algoritmo FP-Growth estándar y Apriori, utilizando métricas como tiempo de ejecución y uso de memoria. Las métricas de evaluación incluyen soporte, confianza y *lift* para las reglas



de asociación generadas. También se emplean técnicas de preprocesamiento como la eliminación de ítems infrecuentes y la ordenación de transacciones por frecuencia.



Resultados principales

- El algoritmo OFIM-FP-Growth superó a Apriori y al FP-Growth estándar en términos de tiempo de ejecución, con una reducción significativa en el número de escaneos de la base de datos.
- En el conjunto de datos Supermarket, se generaron reglas de asociación con alto soporte (e.g., 0.036 para ciertos ítems) y confianza, útiles para estrategias de marketing.
- En el conjunto de datos Mushroom, las reglas ayudaron a identificar combinaciones de características asociadas con la toxicidad, con un *lift* superior a 1, indicando asociaciones significativas.

El artículo demuestra una mejora técnica en FP-Growth, evaluada en *datasets* reales, con aplicaciones prácticas en comercio y bioinformática.



Conclusión

En síntesis, los contenidos presentados en este documento han permitido integrar conceptos y procedimientos orientados a una gestión de datos más precisa, eficiente y alineada con los requerimientos actuales de análisis y toma de decisiones. La articulación de herramientas tecnológicas y métodos analíticos ha evidenciado cómo el tratamiento sistemático de la información se traduce en mejoras tangibles para el desempeño organizacional.

La comprensión y aplicación de estas metodologías no solo fortalecen las competencias técnicas, sino que también potencian la capacidad de evaluar escenarios, reconocer patrones y anticipar tendencias. Esto adquiere especial relevancia en entornos laborales donde la información oportuna y bien interpretada constituye un activo estratégico para la competitividad y la innovación.

Finalmente, se destaca que la apropiación de estos conocimientos y su práctica constante contribuyen al desarrollo de un perfil profesional capaz de responder a los desafíos de un contexto cada vez más orientado al uso inteligente de datos. De esta manera, se fomenta una visión integral que une el rigor técnico con la capacidad de análisis crítico y la toma de decisiones fundamentadas.



Referencias bibliográficas

Al-Badani, M. A. & Al-Khulaidi, A. A. (2024). Developing an Efficient FP-Growth Algorithm using Ordered Frequent Itemsets Matrix for Big Data. *International Journal of Intelligent Systems and Applications in Engineering*, 12(3), 508–516.

Ismarmiaty, I. & Rismayati, R. (2023). *Product Sales Promotion Recommendation Strategy with Purchase Pattern Analysis FP-Growth Algorithm*. SinkrOn. 8. 202-211. 10.33395/sinkron.v8i1.11898.

VanderPlas, J. (2017). *Python Data Science Handbook: Essential Tools for Working with Data*. O'Reilly Media.